Introduction aux formats de fichiers et algorithmes utilis?s dans le TP2

November 26, 2018

1 Formats de fichiers

1.1 FASTA

Le fichier FASTA contient des séquences identifiées et annotés brièvement par une description.

```
>ID DESCRIPTION SEQUENCE
```

>NM_001025782.2 Caenorhabditis elegans Phosphatidylinositol 3-kinase catalytic subunit type 3

 ${\tt ATGCGAGTCTCCACGTCAGTCAACGGTGTTTGGGATTTTTCGGCCTGTACCCGTTACTGTGTAGCTGATCCTGAACT}$

```
In [3]: def read_fasta(path):
    with gzip.open(path, 'rt') as f:
        accession, description, seq = None, None, None
    for line in f:
        if line[0] == '>':
            # yield current record
            if accession is not None:
                 yield accession, description, seq

# start a new record
        accession, description = line[1:].rstrip().split(maxsplit=1)
            seq = ''
        else:
        seq += line.rstrip()
```

```
In [4]: next(read_fasta('GCF_000002985.6_WBcel235_rna.fna.gz'))
Out[4]: ('NM_001025782.2',
        'Caenorhabditis elegans Phosphatidylinositol 3-kinase catalytic subunit type 3 (vps-3-
        'ATGCGAGTCTCCACGTCAGTCAACGGTGGTGTTGGGATTGTTTCGGCCTGTACCCGTTACTGTGTAGCTGATCCTGAACTTCTT
1.2 FASTQ
Le format FASTQ contient des fragments annotés avec une qualité pour chaque symboles lus par
le système de séquençage.
@SEQID DESCRIPTION
SEQUENCE
QUALITY
In [5]: with gzip.open('reads.fastq.gz', 'rt') as f:
          print(f.readline())
          print(f.readline())
          print(f.readline())
          print(f.readline())
@VOGKRUTI 1:11:1
In [6]: def read_fastq(path):
          with gzip.open(path, 'rt') as f:
              for line in f:
                 seqid, description = line[1:].rstrip().split(maxsplit=1)
                 sequence = f.readline().rstrip()
                 _ = f.readline()
                 quality = f.readline().rstrip()
                 yield seqid, description, sequence, quality
In [7]: next(read_fastq('reads.fastq.gz'))
Out[7]: ('VOGKRUTI',
       '1:11:1',
        'ACTCGATTTACTTGTACTGGAACGAGTTGCCAGTTGAGAGCGCATTCCCAGTGAGAGCCCGATCGTCTGCCGAAGACTTGCCGA
        · -----
```

for _ in read_fastq('reads.fastq.gz'):

In [8]: %%time

pass

```
CPU times: user 1.82 s, sys: 16.9 \text{ ms}, total: 1.84 \text{ s} Wall time: 1.85 \text{ s}
```

1.3 **BED**

Le format BED est un format tabulaire de 3 à 12 colonnes qui contient des annotations de sousséquences.

```
reference start end name
```

Dans ce TP, nous utiliserons seulement les 4 premières colonnes pour identifier la référence, une paire de coordonnées (début, fin) et l'identifiant du contig assemblé depuis notre graphe de Brujin.

2 Notions de base et algorithmes

3 *k*-mer

Sous-séquence de longueur k. Une chaîne de longueur l possède l-k+1 k-mers.

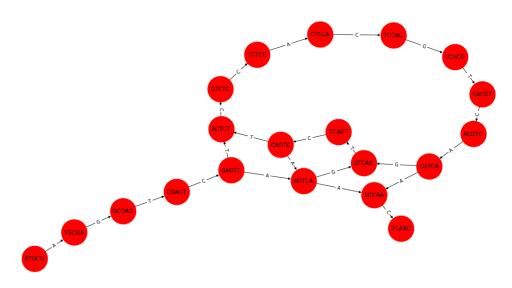
GTCTCCACGTCAGTCAACGGT
TCTCCACGTCAGTCAACGGTG
CTCCACGTCAGTCAACGGTGG
TCCACGTCAGTCAACGGTGGT

4 Graphe de Brujin

Les sommets sont les *k*-mers et les arcs sont les transition sur un symbole de l'aphabet.

```
In [14]: seq[:10+k]
Out [14]: 'ATGCGAGTCTCCACGTCAGTCAACGGTGGTG'
In [15]: k = 7
         kmers = [seq[i:i+k] for i in range(1 - k + 1)]
         def edges(kmers_graph):
             for k in kmers_graph:
                 for s in 'ATCG':
                     successor = k[1:] + s
                     if successor in kmers_graph:
                         yield k, successor
         for v1, v2 in islice(edges(set(kmers[:10])), 10):
             print(v1, v2, 'transition on {}'.format(v2[-1]))
GTCTCCA TCTCCAC transition on C
AGTCTCC GTCTCCA transition on A
ATGCGAG TGCGAGT transition on T
CGAGTCT GAGTCTC transition on C
GAGTCTC AGTCTCC transition on C
TCTCCAC CTCCACG transition on G
GCGAGTC CGAGTCT transition on T
CTCCACG TCCACGT transition on T
TGCGAGT GCGAGTC transition on C
In [16]: import networkx as nx
         %matplotlib inline
         import matplotlib.pyplot as plt
         k = 5
         kmers = [seq[i:i+k] for i in range(1 - k + 1)]
         plt.figure(figsize=(16,8))
         g = nx.DiGraph()
         g.add_nodes_from(set(kmers[:20]))
```

g.add_edges_from((u, v, {'label': v[-1]}) for u, v in edges(set(kmers[:20])))
nx.draw(g, pos=nx.drawing.nx_agraph.graphviz_layout(g), with_labels=True, node_size=30
nx.draw_networkx_edge_labels(g, pos=nx.drawing.nx_agraph.graphviz_layout(g), edge_labels(plt.show())



5 k-mer walk

Lorsque vous traverserez votre graphe, vous devrez adapter cette technique puisqu'il pourra exister plusieurs candidats potentiels et il sera également possible de revenir sur ses pas (i.e. une boucle).

```
kmer_graph = set(kmers)
         contig = None
         for k in islice(kmer_walk(kmer_graph, start='GATGCATTAGAATTACTTTCA'), 20):
             if contig is None:
                 contig = k
             else:
                 contig += k[-1]
             print(((len(contig) - len(k)) * ' ') + k)
         print(contig)
GATGCATTAGAATTACTTTCA
 ATGCATTAGAATTACTTTCAA
 TGCATTAGAATTACTTTCAAG
  GCATTAGAATTACTTTCAAGT
    CATTAGAATTACTTTCAAGTG
     ATTAGAATTACTTTCAAGTGC
      TTAGAATTACTTTCAAGTGCA
       TAGAATTACTTTCAAGTGCAT
        AGAATTACTTTCAAGTGCATT
         GAATTACTTTCAAGTGCATTC
          AATTACTTTCAAGTGCATTCA
           ATTACTTTCAAGTGCATTCAC
            TTACTTTCAAGTGCATTCACT
             TACTTTCAAGTGCATTCACTC
              ACTTTCAAGTGCATTCACTCA
               CTTTCAAGTGCATTCACTCAT
                TTTCAAGTGCATTCACTCATC
                 TTCAAGTGCATTCACTCATCC
                  TCAAGTGCATTCACTCATCCG
                   CAAGTGCATTCACTCATCCGG
GATGCATTAGAATTACTTTCAAGTGCATTCACTCATCCGG
In [19]: print(seq[seq.find(contig)-10:seq.find(contig)+110])
         print(10 * ' ' + contig)
```

TGAAGCTGAAGATGCATTAGAATTACTTTCAAGTGCATTCACTCATCCGGCAGTTCGTGCATATTCTGTATCCCGTCTTCTAGAAGCTGCTTCTCGGCAGTTCACTCATCCGG

6 Exemple de cycle

La solution générale pour un cycle est de mémoriser les endroits déjà visité du graphe et d'interrompre le parcours.

```
In [20]: k = 6

kmers = [seq[i:i+k] for i in range(1 - k + 1)]
```

```
contig = None
         closed = set()
         for k in islice(kmer_walk(kmers, start='GATGCA'), 40):
             if contig is None:
                 contig = k
             else:
                 contig += k[-1]
             print(((len(contig) - len(k)) * ' ') + k, 'already visited!' if k in closed else
             if k in closed:
                 break # stop traversal on repeat
                 closed.add(k)
         print(contig)
GATGCA
 ATGCAA
  TGCAAA
   GCAAAA
    CAAAAA
     AAAAT
      AAAATA
       AAATAT
        ATATA
         ATATAC
          TATACA
           ATACAA
            TACAAA
             ACAAAA
              CAAAAA already visited!
GATGCAAAAATATACAAAAA
```

7 Produire des identifiants aléatoires